Лабораторна робота № 3

Діагностика шкал вимірювання

Курс СК26 «Інтелектуальний аналіз та візуалізація даних»

Тривалість: 2 год аудиторно + 3 год самостійно · **Оцінка:** 4 бали **Файли:** `Ковід_дані_навчальні.xlsx`, `ЛР3_помилковий_аналіз.ipynb`

Шкала вимірювання визначає, які операції над змінною взагалі мають сенс. Комп'ютер цього не знає: він порахує середнє від номера телефону й не поскаржиться. Знати має вимірювач.

У цій роботі ви складаєте **паспорт восьми змінних** свого варіанта, показуєте на власних даних, які статистики для них недопустимі, і виправляєте чужий аналіз, де таких помилок десять.

In [1]:
```
ПРІЗВИЩЕ_ІМЯ = 'Михайло Білоусов'      # напишіть тут своє прізвище та ім'я
ГРУПА        = 'ШІ-32'
НОМЕР        = 2       # ваш номер за списком групи (1–30)

assert ПРІЗВИЩЕ_ІМЯ and ГРУПА and НОМЕР, 'Заповніть три поля вище'
assert 1 <= НОМЕР <= 30, 'Номер має бути від 1 до 30'
```

In [2]:
```
import json
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import warnings
warnings.filterwarnings('ignore')

pd.set_option('display.max_colwidth', 60)

ВАРІАНТИ = json.load(open('lr3_variants_student.json'))
В = ВАРІАНТИ[НОМЕР - 1]

print('=' * 74)
print(f'ВАРІАНТ {В["варіант"]}   ·   {ПРІЗВИЩЕ_ІМЯ}   ·   {ГРУПА}')
print('=' * 74)
print()
print('Ваші вісім стовпців:')
for i, c in enumerate(В['стовпці'], 1):
    print(f'   {i}. {c}')
print()
print('Ваша пара для аналізу зв’язку:', ' та '.join(В['пара']))
print()
```

```
print('Ваше додаткове питання:')
print('  ', B['питання'])
```

```
================================================================================
ВАРІАНТ 2   ·   Михайло Білоусов   ·   ШІ-32
================================================================================

Ваші вісім стовпців:
   1. Телефон
   2. Супутній
   3. ЛН
   4. Дата розтину
   5. КТ
   6. Фібрин1
   7. Сечов2
   8. ФЕРИТ1

Ваша пара для аналізу зв’язку: ЛН та помер/жив

Ваше додаткове питання:
   Стовпець «АТ пост» містить значення на кшталт «140/100». Запропонуйте три способи перетворити його на числові ознаки та обґрунтуйте, який із них візьмете в модель.
```

In [3]:
```
ФАЙЛ = 'Ковід_дані_навчальні.xlsx'
df = pd.read_excel(ФАЙЛ, sheet_name='Лист1', engine='openpyxl')
МОЇ = B['стовпці']

print('Розмір набору:', df.shape)
df[МОЇ].head(8)
```

```
Розмір набору: (121, 77)
```

Out[3]:

	Телефон	Супутній	ЛН	Дата розтину	КТ	Фібрин1	Сечов2	ФЕРИТ1
0	0958469788 дружина Ганна	ІХС, КС, СН1, НВ ФК2	III-IV	2022-03-11	20-30%	4	6.5	NaN
1	0671778486, 0994887663 дружина Оксана	ЦД, II тип	II-III	NaT	30-35%	5	4	839.0
2	0958768045, чоловік Степан 0951784726	ІХС. КС, ГХІІ, ГЛШ СНІІа, порушення толерантності до глю...	II	NaT	70-80%	5.29	10.1	NaN
3	0959819331. дочка Валентина 0960845205	ЦД, II тип, ІХС, Диф кардіоск, стенокар напруги, синусов...	III-IV	NaT	0.8	2.5	12.5	NaN
4	0952294866, дочка Дарина 0678360161	ІХС ДК ГХІІ-ІІІ СНІІа ГЛШст3	II-III	NaT	NaN	4.29	7.4	NaN
5	0959922983 сестра Софія	ІХС ДК ГХІІ ГЛШ СНІІ ФК2, ЦД II	II-III	2021-12-26	30-40%	5	21.4	NaN
6	0998073702, дружина Наталія 0998382226	ІХС ДК ГХ IIа ФК3, ЦД вперше виявлений	II-III	NaT	60-65%	3.24	6.1	NaN
7	0637258771, син Сергій 0968413301	ІХС ДК ГХІІ ГЛШ СНІІа ФК3, полімедик алергія,ерозивий г/...	I	NaT	до 17%	5.04	7.6	NaN

Етап 1. Паспорт змінних

Для кожного з восьми стовпців визначте шкалу вимірювання. Спирайтеся не на тип даних у pandas, а на **зміст величини**: що означають її значення і які порівняння між ними мають сенс.

Нагадування:

Шкала	Ознака
Номінальна	значення можна лише порівняти на рівність
Порядкова	є природний порядок, але відстані між сусідніми рівнями невідомі
Інтервальна	різниці мають сенс, нуль умовний
Відношень	є природний нуль, відношення мають сенс
Абсолютна	природні і нуль, і одиниця вимірювання

Окремо позначайте **ідентифікатори** — значення, що не є величиною взагалі (номер історії хвороби, прізвище, телефон).

In [4]:
```
# Спершу подивіться, що каже pandas — і не довіряйте йому
df[МОЇ].info()
print('-'*74)
df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 121 entries, 0 to 120
Data columns (total 8 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   Телефон       120 non-null    object
 1   Супутній      115 non-null    str
 2   ЛН            121 non-null    str
 3   Дата розтину  61 non-null     datetime64[us]
 4   КТ            44 non-null     object
 5   Фібрин1       115 non-null    object
 6   Сечов2        102 non-null    object
 7   ФЕРИТ1        2 non-null      float64
dtypes: datetime64[us](1), float64(1), object(4), str(2)
memory usage: 7.7+ KB
--------------------------------------------------------------------------------
<class 'pandas.DataFrame'>
RangeIndex: 121 entries, 0 to 120
Data columns (total 77 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   помер/жив       121 non-null    int64
 1   номер і/х       121 non-null    object
 2   ПІП             121 non-null    str
 3   Вік             121 non-null    int64
 4   Стать           121 non-null    str
 5   Телефон         120 non-null    object
 6   Діагноз         121 non-null    str
 7   Перебіг         121 non-null    str
 8   ЛН              121 non-null    str
 9   Ускладнення     61 non-null     str
 10  Супутній        115 non-null    str
 11  КТ              44 non-null     object
 12  ступінь КТ      42 non-null     str
 13  КТ опис         10 non-null     str
 14  spO2 без дот    120 non-null    float64
 15  spO2 з дот      102 non-null    float64
 16  spO2 випис      68 non-null     object
 17  Днів до поступ  120 non-null    object
 18  Поступлення     120 non-null    datetime64[us]
 19  Виписка         120 non-null    object
 20  Ліжко днів      120 non-null    object
 21  Дата розтину    61 non-null     datetime64[us]
 22  Т вище38        77 non-null     object
 23  Т вище 37,5     78 non-null     object
 24  Т 37-37,5       66 non-null     object
 25  АТ пост         120 non-null    str
 26  АТ стац         120 non-null    str
 27  Дотація         102 non-null    object
 28  УЗД             115 non-null    str
 29  Гемогл1         119 non-null    object
 30  Гемогл2         105 non-null    object
 31  Л1              117 non-null    float64
 32  Л2              104 non-null    float64
 33  П/Я 1           117 non-null    float64
 34  П/Я2            104 non-null    float64
```

```
 35  С/Я1            117 non-null    float64
 36  С/Я2            104 non-null    float64
 37  Лім1            117 non-null    float64
 38  Лім2            104 non-null    float64
 39  ШОЕ1            117 non-null    float64
 40  ШОЕ2            104 non-null    float64
 41  СРБ1            95 non-null     float64
 42  СРБ2            83 non-null     float64
 43  ІЛ6-1           20 non-null     float64
 44  ІЛ6-2           6 non-null      float64
 45  ФЕРИТ1          2 non-null      float64
 46  Д-дим1          59 non-null     object
 47  Д-дим2          30 non-null     object
 48  ФЕРИТ2          1 non-null      float64
 49  Прокальцитонін  46 non-null     float64
 50  Гематокрит1     115 non-null    float64
 51  Гематокрит2     101 non-null    float64
 52  Прот час1       112 non-null    float64
 53  Прот час2       100 non-null    float64
 54  Фібрин1         115 non-null    object
 55  Фібрин2         101 non-null    float64
 56  МНВ1            90 non-null     float64
 57  МНВ2            76 non-null     object
 58  Білок1          118 non-null    float64
 59  Білок2          105 non-null    object
 60  Сечов1          117 non-null    float64
 61  Сечов2          102 non-null    object
 62  Креат1          117 non-null    object
 63  Креат2          102 non-null    object
 64  БР заг1         110 non-null    float64
 65  БРзаг2          101 non-null    float64
 66  БРпр1           109 non-null    float64
 67  БРпр2           99 non-null     object
 68  БРнепр1         108 non-null    float64
 69  БРнепр2         98 non-null     float64
 70  АЛАТ1           115 non-null    float64
 71  АЛАТ2           105 non-null    float64
 72  АСАТ1           114 non-null    float64
 73  АСАТ2           104 non-null    float64
 74  Цукор1          118 non-null    float64
 75  Цукор2          104 non-null    float64
 76  Примітка        45 non-null     str
dtypes: datetime64[us](2), float64(38), int64(2), object(22), str(13)
memory usage: 72.9+ KB
```

In [5]:

```python
# Далі — що є всередині насправді
for c in МОЇ:
    з = df[c].dropna()
    типи = ', '.join(f'{t.__name__}×{n}' for t, n in з.map(type).value_count
    print(f'--- {c}')
    print(f'    непорожніх {len(з)} з {len(df)} | унікальних {з.nunique()} |
    print(f'    приклади: {[repr(v) for v in з.unique()[:4]]}')
    print()
```

```
--- Телефон
    непорожніх 120 з 121 | унікальних 120 | типи: str×97, int×23
    приклади: ["'0958469788 дружина Ганна'", "'0671778486, 0994887663 дружин
а Оксана'", "'0958768045, чоловік Степан 0951784726'", "'0959819331. дочка В
алентина 0960845205'"]

--- Супутній
    непорожніх 115 з 121 | унікальних 91 | типи: str×115
    приклади: ["'ІХС, КС, СН1, НВ ФК2'", "'ЦД, ІІ тип'", "'ІХС. КС, ГХІІ, ГЛ
Ш СНІІа, порушення толерантності до глюкози'", "'ЦД, ІІ тип, ІХС, Диф кардіо
ск, стенокар напруги, синусова тахік, ГХІІ, СНІІв '"]

--- ЛН
    непорожніх 121 з 121 | унікальних 6 | типи: str×121
    приклади: ["'III-IV'", "'II-III'", "'II'", "'I'"]

--- Дата розтину
    непорожніх 61 з 121 | унікальних 50 | типи: Timestamp×61
    приклади: ["Timestamp('2022-03-11 00:00:00')", "Timestamp('2021-12-26 0
0:00:00')", "Timestamp('2021-11-19 00:00:00')", "Timestamp('2022-05-13 00:0
0:00')"]

--- КТ
    непорожніх 44 з 121 | унікальних 26 | типи: float×27, str×17
    приклади: ["'20-30%'", "'30-35%'", "'70-80%'", '0.8']

--- Фібрин1
    непорожніх 115 з 121 | унікальних 87 | типи: float×93, int×21, str×1
    приклади: ['4', '5', '5.29', '2.5']

--- Сечов2
    непорожніх 102 з 121 | унікальних 66 | типи: float×79, int×22, str×1
    приклади: ['6.5', '4', '10.1', '12.5']

--- ФЕРИТ1
    непорожніх 2 з 121 | унікальних 2 | типи: float×2
    приклади: ['np.float64(839.0)', 'np.float64(271.1)']
```

Заповніть паспорт

Для кожного стовпця вкажіть шкалу та **обґрунтування** — одне речення про те, чому саме ця шкала. Обґрунтування оцінюється, назва шкали сама по собі — ні.

In [6]:
```python
ПАСПОРТ = {
    # 'назва стовпця': ('шкала', 'обґрунтування однією фразою'),
    'Телефон': ('ідентифікатор', 'виділяє конкретний випадок у датасеті'),
    'Супутній': ('номінальна', 'визначає конкретне захворювання, можна порів
    'ЛН': ('порядкова', 'легенева недостатність, можна порівняти ступені'),
    'Дата розтину': ('інтервальна', 'timestamp, також витік даних бо розтин
    'КТ': ('відношень', 'відсоток ураження? за дослідженням кт'),
    'Фібрин1': ('абсолютна', 'вимір кількості речовини, є природня од вимірю
    'Сечов2': ('абсолютна', 'вимір кількості речовини, є природня од вимірюв
    'ФЕРИТ1': ('абсолютна', 'вимір кількості речовини, є природня од вимірюв
}
```

```
for c in МОЇ:
    ПАСПОРТ.setdefault(c, ('', ''))

паспорт_df = pd.DataFrame(
    [(c, ПАСПОРТ[c][0], ПАСПОРТ[c][1]) for c in МОЇ],
    columns=['Стовпець', 'Шкала', 'Обґрунтування'])
паспорт_df
```

Out[6]:

	Стовпець	Шкала	Обґрунтування
0	Телефон	ідентифікатор	виділяє конкретний випадок у датасеті
1	Супутній	номінальна	визначає конкретне захворювання, можна порівняти тільки ...
2	ЛН	порядкова	легенева недостатність, можна порівняти ступені
3	Дата розтину	інтервальна	timestamp, також витік даних бо розтин можливий лише для...
4	КТ	відношень	відсоток ураження? за дослідженням кт
5	Фібрин1	абсолютна	вимір кількості речовини, є природня од вимірювання
6	Сечов2	абсолютна	вимір кількості речовини, є природня од вимірювання
7	ФЕРИТ1	абсолютна	вимір кількості речовини, є природня од вимірювання

In [7]:
```
# --- САМОПЕРЕВІРКА 1 ---
ДОПУСТИМІ = {'номінальна', 'порядкова', 'інтервальна', 'відношень',
             'абсолютна', 'ідентифікатор'}
for c in МОЇ:
    ш, об = ПАСПОРТ[c]
    assert ш.strip().lower() in ДОПУСТИМІ, f'{c}: шкалу «{ш}» не розпізнано'
    assert len(об.strip()) >= 25, f'{c}: обґрунтування закоротке'
print('Самоперевірка 1 пройдена: усі вісім стовпців мають шкалу та обґрунтув
```

```
Самоперевірка 1 пройдена: усі вісім стовпців мають шкалу та обґрунтування.
```

Етап 2. Допустимі статистики

Для кожного стовпця обчисліть **тільки те, що дозволяє його шкала**.

- номінальна та ідентифікатор — мода, частоти
- порядкова — додатково медіана та квантилі
- інтервальна — додатково середнє та стандартне відхилення
- відношень і абсолютна — усе, зокрема коефіцієнт варіації

Якщо для стовпця не можна порахувати нічого, крім частот, — так і напишіть.

In [8]:
```python
def допустима_статистика(стовпець, шкала):
    """Повертає словник статистик, дозволених для цієї шкали."""
    з = df[стовпець].dropna()
    р = {'непорожніх': len(з), 'унікальних': з.nunique()}
    ш = шкала.strip().lower()

    if ш in ('ідентифікатор',):
        return р
    # ваш код: додайте моду й частоти для всіх шкал
    # для порядкової — медіану та квантилі
    # для інтервальної та вище — середнє й стандартне відхилення
    # для відношень і абсолютної — коефіцієнт варіації
    р['mode'] = з.mode().iloc[0] if len(з) else None
    р['freq'] = з.value_counts().to_dict()
    if pd.api.types.is_datetime64_any_dtype(з):
        vals = з.astype('int64').astype(float)
    else:
        num = pd.to_numeric(з, errors='coerce')
        vals = num.astype(float) if num.notna().all() else None
    if ш == 'порядкова':
        if vals is not None:
            р['median'] = vals.median()
            р['quantiles'] = vals.quantile([0.25, 0.5, 0.75]).to_dict()
    elif ш in ('інтервальна', 'відношень', 'абсолютна'):
        if vals is not None:
            р['mean'] = vals.mean()
            р['std'] = vals.std()
            if ш in ('відношень', 'абсолютна') and vals.mean():
                р['cv'] = vals.std() / vals.mean()
    return р


for с in МОЇ:
    print(f'--- {с}  ({ПАСПОРТ[с][0]})')
    print('   ', допустима_статистика(с, ПАСПОРТ[с][0]))
    print()
```

--- Телефон (ідентифікатор)
    {'непорожніх': 120, 'унікальних': 120}

--- Супутній (номінальна)
    {'непорожніх': 115, 'унікальних': 91, 'mode': 'ІХС ДК ГХст2', 'freq': {'ІХС ДК ГХст2': 7, 'ІХС.ДК. ГХ ІІ': 5, 'ІХС ДК ГХст2.': 4, 'ІХС.ДК .Атеросклероз аорти. Первинно зморщені нирки': 3, 'Хрон гастродуоденіт': 2, 'ІХС ДК ГХст2 СНІІа': 2, 'ІХС ДК ГХст3': 2, 'ІХС.ДК. ХОЗЛ. ГХ ІІ': 2, 'ІХС.ДК. ГХ І І. ЦД ': 2, 'ІХС ДК ГХ ІІ СНІІа ФК3': 2, 'ІХС ДК ГХст2. ЦД': 2, 'ІХС.ДК. ЦД. Атеросклероз аорти': 2, 'ІХС ДК ГЛШ ст2 СН ІІА ': 2, 'ІХС, КС, СН1, НВ ФК2': 1, 'ЦД, ІІ тип': 1, 'ІХС. КС, ГХІІ, ГЛШ СНІІа, порушення толерантності до глюкози': 1, 'ЦД, ІІ тип, ІХС, Диф кардіоск, стенокар напруги, синусова тахік, ГХІІ, СНІІв ': 1, 'ІХС ДК ГХІІ-ІІІ СНІІа ГЛШст3': 1, 'ІХС ДК ГХІІ ГЛШ СНІІ ФК2, ЦД ІІ': 1, 'ІХС ДК ГХ ІІа ФК3, ЦД вперше виявлений': 1, 'ІХС ДК ГХІІ ГЛШ СНІІа ФК3, полімедик алергія,ерозивий г/дуоденіт': 1, 'ІХС ДК ГХ2 ГЛШст2 КВР 3 СН2 ФК3, ЦД2, Cr прав молоч залози після промен терап': 1, 'ІХС. Фібриляція передсердь': 1, 'ІХС ДК Післяпневмонічний дифузний базальний фіброз легень': 1, 'ГХ 2-3ст, ЦД вперше виявлений': 1, 'ІХС Стенокар напруги, тахісист в аріан, ГХст3': 1, 'ІХС ДК': 1, 'ІХС ДК . ГХ ІІІ': 1, 'ІХС Післяінфар кардіоск, ГХст3, фібриляція передсер,шлун екстрасисит аритмія': 1, 'ЦД': 1, 'ЦД тип 2, ІХС ДК ГХст2 ГЛШ СНІІа': 1, 'ІХС ДК ГХст2 ГЛШст3 СН2': 1, 'ЦЖ ІІ тип': 1, 'ЦД тип 2, ІХС ДК СНст1 ФК ІІІ': 1, 'ІХС ДК СН2ст': 1, 'ІХС Післяінфар кардіоск, ГХст3, ГЛШ СН2а': 1, 'ЦД 2тип, ІХС ДК ГХст2 ГЛШ СН2а Фібр передсер': 1, 'ІХС ДК ГХст2 ГЛШст2 Опасистість2ст': 1, 'ІХС ДК Стенок напруги ГХст2а ЦД Іі тип': 1, 'ІХС Стабільна стенок напруги, ГХст3, ГЛШст2': 1, "ІХС.ДК СНмт2а Анемія важк ст нез'яс генезу.Хрон холицистит": 1, 'ІХС Стабільна стенок напруги, ': 1, 'ГХст2ГЛШст2 Медикаментозна алергія': 1, 'ІХС ДК ГХст2 СН1 ': 1, 'ЦД тип ІІ, ІХС ДК ГХ2 ГЛШст2 СН2а': 1, 'ЦД тип ІІ вперше вияв ІХС ДК ГХ2 ГЛШст2 СН2а': 1, 'ЦД тип ІІ вперше вияв ІХС ДК ГХ2 ГЛШст2 СН2а. Хрон нирк недостІІст, хрон пієлонефрит': 1, 'ГХ 2 ГЛШст2 СН І ': 1, 'ЦД тип ІІ, ІХС ДК Стенокардія напруги ГХст2': 1, 'ІХС.ДК. ГХ ІІІ. Гіпотериоз': 1, 'ІХС.ДК. Шл екстрасит ': 1, 'ІХС.ДК. ХОЗЛ': 1, 'ІХС.Стенокардія напруги': 1, 'ІХС.ДК. ': 1, 'Хрон. Ероз. гастродуоденіт': 1, 'хр.панкреатит. Диф нетокс зоб.ХОЗЛ': 1, 'ІХС.ДК. ГХ ІІ. Міокардит .Аритмія': 1, 'Хр.тонзиліт ': 1, 'ІХС.ДК. ГХ ІІ.Анемія середн.важк': 1, 'Хр.Гастроентероколіт ': 1, 'ІХС.ДК. ХОЗЛ. Остеоартроз': 1, 'ІХС.ДК. ГХ ІІ. ЦД .Рак молочної з-зи. Маніакал-депрес синдром': 1, 'ІХС.ДК. ГХ ІІ. ЦД .Рак лівої молочної з-зи. Хронічна анемія': 1, 'ІХС.ДК. ГХ ІІІ': 1, 'ІХС.ДК. Хронічна анемія': 1, 'ІХС.ДК. ЦД. Рак лівої молочної з-зи. ': 1, 'ІХС.ДК. ГХ ІІІ Гепатит': 1, 'ІХС.ДК. ЦД. ГХ ІІІ. ': 1, 'ІХС': 1, 'ІХС.ДК.': 1, 'ІХС ДК СН ІІа ФК 3': 1, 'ІХС ДК ГХ ІІ СН ІІа ФК 3-4 Церебральний атеросклероз': 1, 'ІХС ДК ГХ ІІ СН ІІа ФК 3': 1, 'ІХС ДК ГЛШ ЦД ІІ тип. ': 1, 'ІХС ДК ГХ ІІІ СН ІІА ЦД ІІ тип': 1, 'ІХС ДК ГХст2. Опасистість ІІІ': 1, 'ІХС.ДК. Волога гангрена обох стоп і гомілок': 1, 'ІХС.ДК. ЦД. Атеросклероз аорти.Дифузний ліпоматоз (ожиріння 3)': 1, 'Цукровий діабет Іітип , Опасистість ІІІ': 1, 'ІХС.ДК.ГХ ст2 .Атеросклероз аорти': 1, 'ІХС ДК ГХст2.Емфізема легень': 1, 'ІХС ДК ГХст2.Емфізема легень.Атеросклероз аорти. Первинно зморщені нирки': 1, 'Облітеруючий атеросклероз ниж кінц.оклюзія стегно-підколінного сегменту зліва,ішемія кінц. Хр бронхіт, пієлонефрит. Гепатит С': 1, 'ІХС ДК СН ІІа Атеросклероз аорти та вінцевих судин. ': 1, 'ІХС ДК ГХ Іі СН Ііа Емфізема легень Хрон бронхіт': 1, 'Бронхіальна астма. Емфізема легень. Дифузний пневмосклероз': 1, 'ІХС ДК ГХст2.Атеросклероз аорти. Первинно зморщені нирки': 1, 'Хронічний холецисто-панкреатит': 1, 'ІХС ДК СН ІІа Атеросклероз аорти та вінцевих судин. Кардіомегалія': 1, 'ІХС ДК СН ІІа Атеросклероз аорти та вінцевих судин. Рак лівої молочної залози та сечового міхура': 1, 'Анемія хронічного захворювання важкого ступеня ': 1}}

```
--- ЛН  (порядкова)
    {'непорожніх': 121, 'унікальних': 6, 'mode': 'II-III', 'freq': {'II-II
I': 59, 'II': 21, 'III': 17, 'I': 12, 'I-II': 9, 'III-IV': 3}}

--- Дата розтину  (інтервальна)
    {'непорожніх': 61, 'унікальних': 50, 'mode': Timestamp('2022-06-07 00:0
0:00'), 'freq': {Timestamp('2022-06-07 00:00:00'): 3, Timestamp('2022-04-07
00:00:00'): 2, Timestamp('2022-04-27 00:00:00'): 2, Timestamp('2022-04-13 0
0:00:00'): 2, Timestamp('2022-03-30 00:00:00'): 2, Timestamp('2022-05-06 00:
00:00'): 2, Timestamp('2022-05-22 00:00:00'): 2, Timestamp('2022-04-10 00:0
0:00'): 2, Timestamp('2022-05-03 00:00:00'): 2, Timestamp('2022-04-30 00:00:
00'): 2, Timestamp('2022-03-11 00:00:00'): 1, Timestamp('2021-12-26 00:00:0
0'): 1, Timestamp('2021-11-19 00:00:00'): 1, Timestamp('2022-05-13 00:00:0
0'): 1, Timestamp('2022-06-18 00:00:00'): 1, Timestamp('2022-04-09 00:00:0
0'): 1, Timestamp('2022-04-15 00:00:00'): 1, Timestamp('2022-03-24 00:00:0
0'): 1, Timestamp('2022-04-26 00:00:00'): 1, Timestamp('2022-03-29 00:00:0
0'): 1, Timestamp('2022-04-05 00:00:00'): 1, Timestamp('2022-04-24 00:00:0
0'): 1, Timestamp('2022-04-20 00:00:00'): 1, Timestamp('2022-05-01 00:00:0
0'): 1, Timestamp('2022-04-06 00:00:00'): 1, Timestamp('2022-02-03 00:00:0
0'): 1, Timestamp('2022-06-22 00:00:00'): 1, Timestamp('2022-03-05 00:00:0
0'): 1, Timestamp('2022-02-25 00:00:00'): 1, Timestamp('2022-03-02 00:00:0
0'): 1, Timestamp('2022-06-04 00:00:00'): 1, Timestamp('2022-04-29 00:00:0
0'): 1, Timestamp('2021-01-06 00:00:00'): 1, Timestamp('2022-02-10 00:00:0
0'): 1, Timestamp('2022-01-19 00:00:00'): 1, Timestamp('2022-02-24 00:00:0
0'): 1, Timestamp('2022-02-18 00:00:00'): 1, Timestamp('2022-05-29 00:00:0
0'): 1, Timestamp('2022-05-14 00:00:00'): 1, Timestamp('2022-05-18 00:00:0
0'): 1, Timestamp('2022-04-21 00:00:00'): 1, Timestamp('2022-06-03 00:00:0
0'): 1, Timestamp('2022-05-21 00:00:00'): 1, Timestamp('2022-05-17 00:00:0
0'): 1, Timestamp('2022-04-25 00:00:00'): 1, Timestamp('2022-03-15 00:00:0
0'): 1, Timestamp('2022-02-15 00:00:00'): 1, Timestamp('2022-04-23 00:00:0
0'): 1, Timestamp('2022-05-04 00:00:00'): 1, Timestamp('2022-05-07 00:00:0
0'): 1}, 'mean': np.float64(1649251357377049.2), 'std': np.float64(626967846
6302.692)}

--- КТ  (відношень)
    {'непорожніх': 44, 'унікальних': 26, 'mode': 0.3, 'freq': {0.3: 6, 0.25:
5, 0.8: 3, 0.7: 3, '70-80%': 2, 0.5: 2, '65-70%': 2, '25-30%': 2, 0.4: 2, '2
0-30%': 1, '30-35%': 1, '30-40%': 1, '60-65%': 1, 'до 17%': 1, 0.15: 1, 0.0
5: 1, 0.08: 1, '25-35 %': 1, '45-50%': 1, 0.1: 1, '60-70': 1, '40-45%': 1,
'50-75%': 1, 0.6: 1, '           ': 1, 0.35: 1}}

--- Фібрин1  (абсолютна)
    {'непорожніх': 115, 'унікальних': 87, 'mode': 6, 'freq': {6: 6, 7: 5, 4:
4, 5: 4, 5.5: 4, 4.41: 2, 3.55: 2, 4.2: 2, 4.99: 2, 3.99: 2, 4.6: 2, 4.21:
2, 3.8: 2, 5.02: 2, 2.97: 2, 5.29: 1, 2.5: 1, 4.29: 1, 3.24: 1, 5.04: 1, 4.6
6: 1, 6.8: 1, 4.8: 1, 3.92: 1, 2.55: 1, 3.5: 1, 5.6: 1, 2.8: 1, 6.9: 1, 8.3
6: 1, 4.88: 1, 7.77: 1, 2.6: 1, 3.9: 1, 7.16: 1, 6.88: 1, 5.55: 1, 4.55: 1,
5.43: 1, 5.73: 1, 5.41: 1, 4.4: 1, 4.74: 1, 17.13: 1, '5.9.': 1, 9.29: 1, 3.
26: 1, 0.33: 1, 4.77: 1, 8: 1, 7.7: 1, 7.1: 1, 3.81: 1, 3.1: 1, 8.6: 1, 3.9
3: 1, 2.2: 1, 3.94: 1, 7.06: 1, 5.9: 1, 7.6: 1, 3.04: 1, 5.07: 1, 2.15: 1,
4.48: 1, 3.97: 1, 5.01: 1, 6.64: 1, 6.46: 1, 3: 1, 5.2: 1, 5.99: 1, 6.07: 1,
2.43: 1, 5.52: 1, 3.17: 1, 4.57: 1, 3.98: 1, 3.32: 1, 4.85: 1, 5.96: 1, 3.6
4: 1, 7.8: 1, 2.04: 1, 5.7: 1, 6.37: 1, 4.37: 1}}

--- Сечов2  (абсолютна)
    {'непорожніх': 102, 'унікальних': 66, 'mode': 4.9, 'freq': {5: 4, 4.9:
```

```
4, 6.5: 3, 4: 3, 6.1: 3, 7.6: 3, 6.2: 3, 5.5: 3, 10: 3, 7.1: 3, 7.3: 2, 5.9:
2, 6.9: 2, 6.7: 2, 6.8: 2, 6.4: 2, 7.7: 2, 9.4: 2, 8.6: 2, 4.6: 2, 8.1: 2, 1
1.4: 2, 8: 2, 7.2: 2, 10.1: 1, 12.5: 1, 7.4: 1, 21.4: 1, 14.1: 1, 8.2: 1, 7.
8: 1, 5.7: 1, 11.9: 1, 15: 1, 8.4: 1, 7: 1, 4.2: 1, 4.3: 1, 14.2: 1, 10.5:
1, 12.4: 1, 116: 1, 9.7: 1, 3.4: 1, 11: 1, 3.9: 1, 13.6: 1, 70: 1, 5.6: 1, 1
4: 1, 8.8: 1, 19.4: 1, 10.9: 1, 3.7: 1, 12.7: 1, 37: 1, 8.7: 1, 'немає': 1,
12.6: 1, 9.06: 1, 8.3: 1, 4.8: 1, 9: 1, 13.2: 1, 35: 1, 6: 1}}

--- ФЕРИТ1  (абсолютна)
    {'непорожніх': 2, 'унікальних': 2, 'mode': np.float64(271.1), 'freq': {8
39.0: 1, 271.1: 1}, 'mean': np.float64(555.05), 'std': np.float64(401.565941
0358403), 'cv': np.float64(0.723477057987281)}
```

Етап 3. Три безглузді числа

`df.describe()` порахує статистики для всього, що схоже на число. Частина цих чисел не має жодного змісту.

Знайдіть **щонайменше три** такі числа у своєму наборі: обчисліть їх, а потім поясніть, чому кожне з них безглузде.

In [9]:
```
descr = df[МОЇ].describe(include='all').T
descr
```

Out[9]:

	count	unique	top	freq	mean	min	25%	50
Телефон	120	120	0958469788 дружина Ганна	1	NaN	NaN	NaN	Na
Супутній	115	91	ІХС ДК ГХст2	7	NaN	NaN	NaN	Na
ЛН	121	6	II-III	59	NaN	NaN	NaN	Na
Дата розтину	61	NaN	NaN	NaN	2022-04-06 13:22:37.377049	2021-01-06 00:00:00	2022-03-29 00:00:00	202 04-2 00:00:(
КТ	44.0	26.0	0.3	6.0	NaN	NaN	NaN	Na
Фібрин1	115.0	87.0	6.0	6.0	NaN	NaN	NaN	Na
Сечов2	102.0	66.0	5.0	4.0	NaN	NaN	NaN	Na
ФЕРИТ1	2.0	NaN	NaN	NaN	555.05	271.1	413.075	555.(

In [10]:
```
БЕЗГЛУЗДІ = [
    # ('стовпець', 'яка статистика', значення, 'чому це число нічого не озна
    ('Дата розтину', 'mean', descr['mean']['Дата розтину'], 'неможливо пора
```

```
    ('Телефон', 'freq', descr['freq']['Телефон'], 'усі ідентифікатори унікал
    ('Супутній', 'top', descr['top']['Супутній'], 'ця колонка містить декіль
]

assert len(БЕЗГЛУЗДІ) >= 3, 'Потрібно щонайменше три приклади'
pd.DataFrame(БЕЗГЛУЗДІ, columns=['Стовпець', 'Статистика', 'Значення', 'Чому
```

Out[10]:

	Стовпець	Статистика	Значення	Чому безглузде
0	Дата розтину	mean	2022-04-06 13:22:37.377049	неможливо порахувати середній timestamp
1	Телефон	freq	1	усі ідентифікатори унікальні
2	Супутній	top	ІХС ДК ГХст2	ця колонка містить декілька значень в одному рядку, щоб ...

Етап 4. Міра зв'язку для вашої пари

Для двох змінних вашого варіанта треба оцінити зв'язок. Міру обирає **пара шкал**, а не зручність:

Поєднання шкал	Міра
відношень × відношень	кореляція Пірсона
порядкова × порядкова	рангова кореляція Спірмена
номінальна × номінальна	χ^2 та коефіцієнт Крамера (V)
відношень × бінарна номінальна	точковий бісеріальний коефіцієнт
номінальна × порядкова	коефіцієнт Крамера (V)

Обґрунтуйте вибір, обчисліть міру й поясніть результат. Окремо покажіть, **що станеться**, якщо застосувати Пірсона там, де він недопустимий, — і чому отримане число не можна інтерпретувати.

In [11]:
```
A, B = B['пара']
print('Ваша пара:', A, '×', B)
print()
print(f'{A}: шкала —', ПАСПОРТ.get(A, ('не у вашому списку',))[0] or '(визна
print(f'{B}: шкала —', ПАСПОРТ.get(B, ('не у вашому списку',))[0] or '(визна
print()
print(df[[A, B]].head(6).to_string())
```

```
Ваша пара: ЛН × помер/жив

ЛН: шкала — порядкова
помер/жив: шкала — не у вашому списку

       ЛН  помер/жив
0  III-IV          1
1  II-III          2
2      II          2
3  III-IV          2
4  II-III          2
5  II-III          1
```

In [12]:
```python
ОБРАНА_МІРА = 'коефіцієнт Крамера (V)'        # напишіть назву міри
ЧОМУ_САМЕ_ВОНА = 'порядкова х номінальна шкали, тому коефіцієнт крамера'

assert ОБРАНА_МІРА and len(ЧОМУ_САМЕ_ВОНА) >= 40, 'Заповніть обидва поля'

# ваш код: обчисліть обрану міру
from scipy.stats import chi2_contingency
from scipy.stats.contingency import association

t = pd.crosstab(df[A], df[B])
chi2, p, dof, exp = chi2_contingency(t)
n = t.to_numpy().sum()
v = association(t, method='cramer')
print(t)
print('n =', int(n), '| chi2 =', round(chi2, 3), '| df =', dof, '| p =', rou
print('Cramer V =', round(v, 3))
print('мінімальне очікуване =', round(exp.min(), 2))
```

```
помер/жив   1   2
ЛН
I           0  12
I-II        0   9
II          0  21
II-III     49  10
III        11   6
III-IV      1   2
n = 121 | chi2 = 69.58 | df = 5 | p = 0.0
Cramer V = 0.758
мінімальне очікуване = 1.49
```

In [13]:
```python
# Тепер — контрприклад: застосуйте кореляцію Пірсона незалежно від шкал
# і поясніть, чому отримане число не можна використовувати.
from scipy.stats import pearsonr

codes = pd.factorize(df[A])[0]
y = pd.to_numeric(df[B], errors='coerce')
r, p = pearsonr(codes, y)
rc, pc = pearsonr(codes.max() - codes, y)
print('Pearson на довільних кодах ЛН            :', round(r, 3), '| p =', rc
```

```
Pearson на довільних кодах ЛН            : 0.395 | p = 0.0
```

Етап 5. Підготовка змінних до моделі

Шкала визначає не лише статистику, а й спосіб кодування.

Шкала	Як готують до моделі
Номінальна	one-hot кодування; порядок категорій не вводять
Порядкова	впорядкована категорія або цілі коди із **заданим** порядком
Інтервальна	стандартизація; для дат — перехід до тривалостей
Відношень	нормалізація або стандартизація; можливе логарифмування
Ідентифікатор	у модель не беруть узагалі

Для кожного свого стовпця вкажіть спосіб підготовки — і **виконайте його** щонайменше для трьох стовпців різних шкал.

In [14]:
```
ПІДГОТОВКА = {
    # 'стовпець': 'спосіб і коротке обґрунтування',
    'Телефон': 'ідентифікатор — у модель не беремо взагалі',
    'Супутній': 'номінальна — one-hot кодування, порядок категорій не задаєм
    'ЛН': 'порядкова — цілочисельні коди із заданим порядком ступенів',
    'Дата розтину': 'інтервальна — переходимо до тривалості (днів від опорно
    'КТ': 'відношень — узгоджуємо формати й одиниці, далі z-стандартизація',
    'Фібрин1': 'абсолютна — z-стандартизація після перевірки варіативності',
    'Сечов2': 'абсолютна — z-стандартизація після перевірки варіативності',
    'ФЕРИТ1': 'абсолютна — z-стандартизація; n=2, тому ознака фактично непри
}
for c in МОЇ:
    ПІДГОТОВКА.setdefault(c, '')

pd.DataFrame([(c, ПАСПОРТ[c][0], ПІДГОТОВКА[c]) for c in МОЇ],
             columns=['Стовпець', 'Шкала', 'Як готуємо'])
```

Out[14]:

	Стовпець	Шкала	Як готуємо
0	Телефон	ідентифікатор	ідентифікатор — у модель не беремо взагалі
1	Супутній	номінальна	номінальна — one-hot кодування, порядок категорій не зад...
2	ЛН	порядкова	порядкова — цілочисельні коди із заданим порядком ступенів
3	Дата розтину	інтервальна	інтервальна — переходимо до тривалості (днів від опорної...
4	КТ	відношень	відношень — узгоджуємо формати й одиниці, далі z-стандар...
5	Фібрин1	абсолютна	абсолютна — z-стандартизація після перевірки варіативності
6	Сечов2	абсолютна	абсолютна — z-стандартизація після перевірки варіативності
7	ФЕРИТ1	абсолютна	абсолютна — z-стандартизація; n=2, тому ознака фактично ...

In [15]:

```
# ваш код: реалізуйте підготовку для трьох стовпців різних шкал
ln_order = {'I': 1, 'I-II': 2, 'II': 3, 'II-III': 4, 'III': 5, 'III-IV': 6}
ln_codes = df['ЛН'].map(ln_order)
print('ЛН (порядкова) -> коди із заданим порядком:', ln_order)
print('розподіл кодів:', ln_codes.value_counts().sort_index().to_dict())

raw = df['КТ'].astype(str).str.strip()
kt_point = pd.to_numeric(raw.str.replace('%', '', regex=False), errors='coer
kt_range = raw.str.extract(r'(\d+(?:[.,]\d+)?)\s*[-–]\s*(\d+(?:[.,]\d+)?)')
kt_lte = raw.str.extract(r'(?:до|<)\s*(\d+(?:[.,]\d+)?)')
kt_mid = (pd.to_numeric(kt_range[0], errors='coerce') + pd.to_numeric(kt_rar
kt_less = pd.to_numeric(kt_lte[0], errors='coerce')
kt_percent = kt_point.where(kt_point >= 1, kt_point * 100).fillna(kt_mid).fi
kt_std = (kt_percent - kt_percent.mean()) / kt_percent.std()
print('КТ (відношень): після узгодження одиниць n =', int(kt_percent.notna()
      '| min', round(kt_percent.min(), 2), '| max', round(kt_percent.max(),
      '| std', round(kt_percent.std(), 2))
print('КТ z-score: mean', round(kt_std.mean(), 3), '| std', round(kt_std.std

sup_clean = df['Супутній'].dropna().astype(str).str.strip()
sup_dummies = pd.get_dummies(sup_clean, prefix='Супутній', dtype=int)
print('Супутній (номінальна): one-hot колонок', sup_dummies.shape[1],
      '| рядків із заповненим діагнозом', int((sup_dummies.sum(axis=1) > 0).
print('найрідша категорія трапляється', int(sup_clean.value_counts().min()),
```

```
ЛН (порядкова) -> коди із заданим порядком: {'I': 1, 'I-II': 2, 'II': 3, 'II
-III': 4, 'III': 5, 'III-IV': 6}
розподіл кодів: {1: 12, 2: 9, 3: 21, 4: 59, 5: 17, 6: 3}
КТ (відношень): після узгодження одиниць n = 43 | min 5.0 | max 80.0 | std 2
1.97
КТ z-score: mean -0.0 | std 1.0
Супутній (номінальна): one-hot колонок 90 | рядків із заповненим діагнозом 1
15
найрідша категорія трапляється 1 раз(и)
```

Перед нормалізацією обов'язково перевірте варіативність. Стовпець, у якому всі значення однакові, дасть нуль у знаменнику — і мовчазний `NaN` замість помилки.

In [16]:
```
for c in МОЇ:
    з = pd.to_numeric(df[c], errors='coerce').dropna()
    if len(з) and з.nunique() == 1:
        print(f'УВАГА: {c} — сталий стовпець, нормалізація дасть ділення на
    elif len(з) and з.max() == з.min():
        print(f'УВАГА: {c} — max дорівнює min')
print('Перевірку варіативності виконано.')
```

```
Перевірку варіативності виконано.
```

In [17]:
```
# --- САМОПЕРЕВІРКА 2 ---
assert all(len(ПІДГОТОВКА[c].strip()) >= 15 for c in МОЇ), \
    'Для кожного стовпця вкажіть спосіб підготовки'
assert len(БЕЗГЛУЗДІ) >= 3, 'Етап 3 не завершено'
print('Самоперевірка 2 пройдена.')
```

```
Самоперевірка 2 пройдена.
```

Етап 6. Виправлення чужого аналізу

Відкрийте файл **`ЛР3_помилковий_аналіз.ipynb`**. Це звіт, який виконується без жодної помилки й містить десять хибних місць.

Для кожного з десяти заповніть рядок нижче:

- **розділ** — номер розділу звіту;
- **що не так** — яка шкала порушена або яке припущення хибне;
- **чому число неправильне** — що саме воно означає насправді;
- **як правильно** — коректний варіант або обґрунтована відмова від показника.

In [18]:
```
ВИПРАВЛЕННЯ = [
    # (розділ, 'що не так', 'чому число неправильне', 'як правильно'),
    (1, 'середній результат', 'середнє бінарної номінальної ознаки, нічого н
    (2, 'стать', 'змінна має кілька написань однієї статі, неуніфікована', '
    (3, 'середній ступінь', 'середнє порядкової шкали та довільно закодовани
    (4, 'кт', 'to_numeric coerce мовчки відкидає рядкові диапазони', 'уніфік
```

```
    (5, 'сатурація', 'середнє пораховане лише по підмножині непорожніх', 'ча
    (6, 'дата', 'коефіцієнт варіації дат не має змісту для timestamp', 'пере
    (7, 'стать корр з помер', 'Пірсон для номінальних змінних некоректний',
    (8, 'нормалізація числових ознак', 'нормалізуються сталі, ідентифікатори
    (9, 'dropna', 'dropna видаляє більшість рядків і руйнує вибірку', 'запов
    (10, 'рейтинг важливості (дата розтину)', 'дата розтину відома лише для
]

assert len(ВИПРАВЛЕННЯ) == 10, f'Знайдено {len(ВИПРАВЛЕННЯ)} помилок із 10'
for p in ВИПРАВЛЕННЯ:
    assert len(p) == 4 and all(str(x).strip() for x in p), 'Заповніть усі чо
    assert len(str(p[2])) >= 30 and len(str(p[3])) >= 25, 'Пояснення закорот

pd.DataFrame(ВИПРАВЛЕННЯ, columns=['Розділ', 'Що не так', 'Чому число неправ
```

Out[18]:

	Розділ	Що не так	Чому число неправильне	Як правильно
0	1	середній результат	середнє бінарної номінальної ознаки, нічого не вимірює	частки померлих і живих, мода
1	2	стать	змінна має кілька написань однієї статі, неуніфікована	уніфікувати написання статі
2	3	середній ступінь	середнє порядкової шкали та довільно закодованих рангів	медіана й мода із заданим порядком
3	4	кт	to_numeric coerce мовчки відкидає рядкові диапазони	уніфікувати формати й одиниці КТ
4	5	сатурація	середнє пораховане лише по підмножині непорожніх	частка пацієнтів нижче клінічного порогу
5	6	дата	коефіцієнт варіації дат не має змісту для timestamp	перехід до тривалостей або розмах дат
6	7	стать корр з помер	Пірсон для номінальних змінних некоректний	коефіцієнт Крамера V з хі-квадрат
7	8	нормалізація числових ознак	нормалізуються сталі, ідентифікатори, дати й цільова	відсіяти неналежні стовпці перед нормалізацією
8	9	dropna	dropna видаляє більшість рядків і руйнує вибірку	заповнювати пропуски або видаляти лише дати
9	10	рейтинг важливості (дата розтину)	дата розтину відома лише для померлих, витік цілі	видалити дати розтину з ознак моделі

Виправте щонайменше три помилки в коді

Оберіть три з десяти та покажіть правильне обчислення поруч із неправильним.

In [19]:
```python
# ваш код: три правильні обчислення замість хибних
# 1
частка = (df['помер/жив'] == 1).mean()
df['помер/жив'].value_counts(normalize=True)
# 2
стать = (df['Стать'].astype(str).str.strip().str.lower()
           .str.replace('жін', 'ж').str.replace('чол', 'ч')
           .str[0].map({'ч': 'чоловіча', 'ж': 'жіноча'}))
стать.value_counts()
# 7
табл = pd.crosstab(df['Стать'], df['помер/жив'])
from scipy.stats import chi2_contingency
chi2, p, dof, _ = chi2_contingency(табл)
V = (chi2 / (табл.values.sum() * (min(табл.shape) - 1))) ** 0.5
```

Етап 7. Висновки та індивідуальне питання

In [20]:
```python
ВИСНОВКИ = [
    'КТ записано неузгоджено ("20-30%", "до 17%", 0.3), тому числові статист
    'Дата розтину відома тільки для померлих (61 рядок), тому вона протікає
    'Супутній - номінальний вільний текст: 91 унікальний діагноз на 115 запи
]
assert len(ВИСНОВКИ) >= 3 and all(len(в) >= 60 for в in ВИСНОВКИ), \
    'Потрібні три змістовні висновки'
for i, в in enumerate(ВИСНОВКИ, 1):
    print(f'{i}. {в}')
```

```
1. КТ записано неузгоджено ("20-30%", "до 17%", 0.3), тому числові статистик
и обчислюються лише на 43 із 121 рядка і є зміщеними
2. Дата розтину відома тільки для померлих (61 рядок), тому вона протікає ці
льову змінну й не може бути ознакою моделі
3. Супутній - номінальний вільний текст: 91 унікальний діагноз на 115 записі
в, тому one-hot дає 90 розріджених ознак, непридатних без групування
```

In [21]:
```python
print('ВАШЕ ПИТАННЯ:'); print(B['питання']); print()
ВІДПОВІДЬ = """
1. розбити на 2 стовпця через дріб (сист/діаст),
2. залишити лише сист або діаст,
3. визначити середнє між двома і записати в стовпець.
Я б вибрав перший варіант, бо він зберігає найбільше даних про артеріальний
"""
assert len(ВІДПОВІДЬ.strip()) >= 200, 'Відповідь має бути розгорнутою (від 2
print(ВІДПОВІДЬ)
```

```
ВАШЕ ПИТАННЯ:
Стовпець «АТ пост» містить значення на кшталт «140/100». Запропонуйте три сп
особи перетворити його на числові ознаки та обґрунтуйте, який із них візьмет
е в модель.


1. розбити на 2 стовпця через дріб (сист/діаст),
2. залишити лише сист або діаст,
3. визначити середнє між двома і записати в стовпець.
Я б вибрав перший варіант, бо він зберігає найбільше даних про артеріальний
тиск
```

Етап 8. Декларація про використання інструментів ШІ

Користуватися мовними моделями дозволено. Це нормальна інженерна практика.

Обов'язковою є прозорість: ви вказуєте, де саме і як скористалися інструментом — так само, як у науковій статті вказують використане програмне забезпечення. Задекларована допомога порушенням не є.

Порушенням є інше: здати роботу, яку ви не можете пояснити. На захисті вас попросять показати конкретний рядок свого коду, пояснити, чому він саме такий, і внести в нього невелику зміну на місці.

Для кожного етапу оберіть одне з формулювань:

- `'ні'` — інструментами ШІ не користувався
- `'синтаксис'` — питав про назву функції або синтаксис, код писав сам
- `'код, перевірено'` — код згенеровано, я його прочитав, перевірив і розумію
- `'текст, перероблено'` — згенеровано чернетку тексту, яку я переписав по суті
- `'текст, як є'` — згенерований текст залишено майже без змін

In [22]:
```
ДЕКЛАРАЦІЯ = {
    'етап 1 — паспорт змінних':        'ні',
    'етап 2 — допустимі статистики':   'код, перевірено',
    'етап 3 — безглузді числа':        'код, перевірено',
    'етап 4 — міра зв’язку':           'код, перевірено',
    'етап 5 — підготовка до моделі':   'код, перевірено',
    'етап 6 — виправлення аналізу':    'текст, перероблено',
    'етап 7 — висновки й відповідь':   'код, перевірено',
}
```

```
ЩО_САМЕ_Я_ПЕРЕВІРИВ = 'роботу коду, написаного ШІ, синтаксис, читабельність
                       коректність та валідність відповідей, написаних ШІ'
ПІДТВЕРДЖУЮ = True     # я можу пояснити кожен рядок свого коду
                        # і внести в нього зміни на вимогу під час захисту
```

In [23]:
```
# --- ФІНАЛЬНА САМОПЕРЕВІРКА ---
ФОРМУЛЮВАННЯ = {'ні', 'синтаксис', 'код, перевірено', 'текст, перероблено',

перевірки = {
    'заповнено титульні поля':        bool(ПРІЗВИЩЕ_ІМЯ and ГРУПА and НОМЕР)
    'етап 1: паспорт із 8 стовпців':  all(ПАСПОРТ[c][0] and ПАСПОРТ[c][1] fo
    'етап 3: три безглузді числа':    len(БЕЗГЛУЗДІ) >= 3,
    'етап 4: міру обрано й пояснено': bool(ОБРАНА_МІРА and len(ЧОМУ_САМЕ_ВОН
    'етап 5: підготовку описано':     all(len(ПІДГОТОВКА[c].strip()) >= 15 f
    'етап 6: знайдено 10 помилок':    len(ВИПРАВЛЕННЯ) == 10,
    'етап 7: три висновки':           len(ВИСНОВКИ) >= 3,
    'етап 7: відповідь на питання':   len(ВІДПОВІДЬ.strip()) >= 200,
    'декларацію заповнено':           all(v in ФОРМУЛЮВАННЯ for v in ДЕКЛАРА
    'опис перевірки ≥ 120 символів':  len(ЩО_САМЕ_Я_ПЕРЕВІРИВ.strip()) >= 12
    'підтвердження авторства':        ПІДТВЕРДЖУЮ is True,
}

print('ЧЕК-ЛИСТ ГОТОВНОСТІ')
print('=' * 52)
for назва, ок in перевірки.items():
    print(('  ГОТОВО     ' if ок else '  НЕ ГОТОВО ') + назва)
print('=' * 52)

assert all(перевірки.values()), 'Робота не готова до здачі — див. чек-лист в
print()
print(f'Робота варіанта {В["варіант"]} готова до захисту.')
print(f'{ПРІЗВИЩЕ_ІМЯ}, {ГРУПА}')
```

```
ЧЕК-ЛИСТ ГОТОВНОСТІ
====================================================
  ГОТОВО     заповнено титульні поля
  ГОТОВО     етап 1: паспорт із 8 стовпців
  ГОТОВО     етап 3: три безглузді числа
  ГОТОВО     етап 4: міру обрано й пояснено
  ГОТОВО     етап 5: підготовку описано
  ГОТОВО     етап 6: знайдено 10 помилок
  ГОТОВО     етап 7: три висновки
  ГОТОВО     етап 7: відповідь на питання
  ГОТОВО     декларацію заповнено
  ГОТОВО     опис перевірки ≥ 120 символів
  ГОТОВО     підтвердження авторства
====================================================

Робота варіанта 2 готова до захисту.
Михайло Білоусов, ШІ-32
```

Перед здачею

Виконайте **Kernel → Restart & Run All**. Ноутбук має пройти згори донизу без жодної помилки — це перше, що перевіряється на захисті.